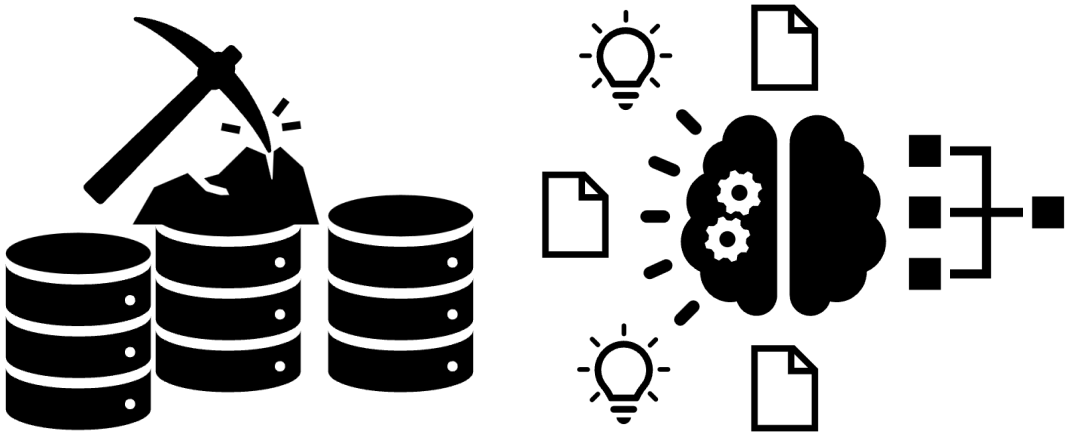
IPD440 - APRENDIZAJE DE MAQUINAS

Clase 1: A Few Useful Things to Know about Machine Learning

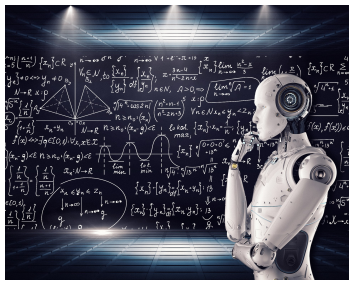
Prof. Nicolás Torres
nicolas.torresr@usm.cl
Ingeniería Civil Telemática
Departamento de Electrónica
Universidad Técnica Federico Santa María

Data Mining vs Machine Learning



Machine learning

El aprendizaje automático o aprendizaje de máquinas tiene como objetivo desarrollar técnicas que permitan a los computadores aprender.

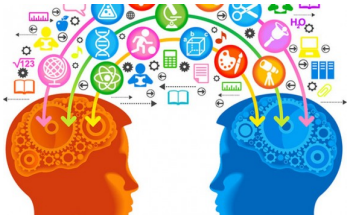


Sin embargo, para desarrollar aplicaciones exitosas con aprendizaje automático se requiere cierta experiencia que puede ser vista como "magia negra" porque no es una receta que viene en los libros.

Aprendizaje

¿Qué es el aprendizaje?

Proceso de adquisición de conocimientos, habilidades, valores, actitudes, destrezas, o conductas.



En los seres humanos, se dice que el aprendizaje produce un cambio relativamente estable en la conducta del individuo.

Entrenamiento

Un modelo recibe y aprende a partir de un conjunto de entrenamiento (*training set*) que contiene ejemplos $(\mathbf{x}_i, y_i)$, donde $\mathbf{x_i} = (x_{i,1}, \ldots, x_{i,d})$ es la entrada observada con d características (*features*) discretas y/o continuas para la salida y_i, que puede ser discreta (clasificación) o continua (regresión) dependiendo del problema.

Testing

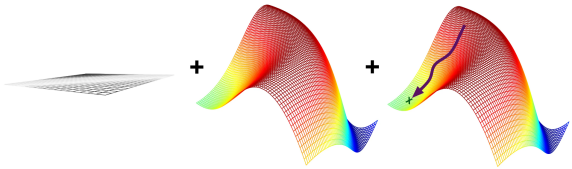
La fase de testing permite evaluar si el modelo produce la salida correcta y_t para ejemplos futuros $\mathbf{x_t} = x_{t,1}, \ldots, x_{t,d}$.

LEARNING = REPRESENTATION + EVALUATION + OPTIMIZATION

Suponga que quiere usar aprendizaje automático para una aplicación, el primer gran problema es decidir que algoritmo utilizar.

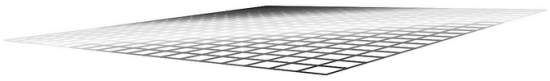
¿Cuál usar? Hay literalmente miles disponibles y cientos más se publican cada año.

Debe enfocarse en 3 componentes:



Representación

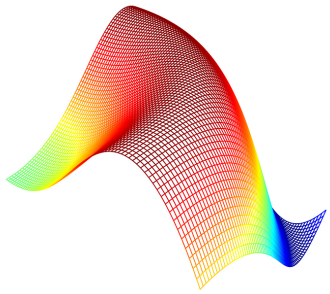
La representación es básicamente el espacio de los modelos permitidos.



Por ejemplo, una SVM con kernel RBF forman un tipo de representación, mientras que una red neuronal feedforward con 3 capas, forma otra.

Evaluación

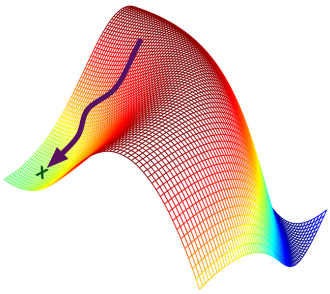
La evaluación es esencialmente cómo juzgar un modelo frente a otro; se le llama función de pérdida (loss), función de costo, función de aptitud (fitness) o función objetivo en otros contextos.



Piense en esto como la altura del espacio para cada modelo dado, siendo las áreas más bajas más preferibles/deseables que las áreas más altas (sin pérdida de generalidad).

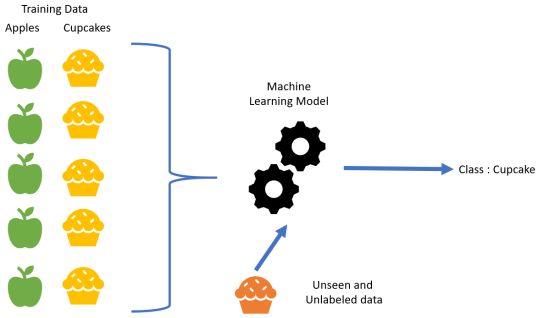
Optimización

La optimización, finalmente, es cómo recorres el espacio de los modelos para obtener mejores evaluaciones. Por ejemplo, descenso del gradiente (gradient descent) o su variante estocástica son formas de encontrar el mínimo en una función de pérdida.



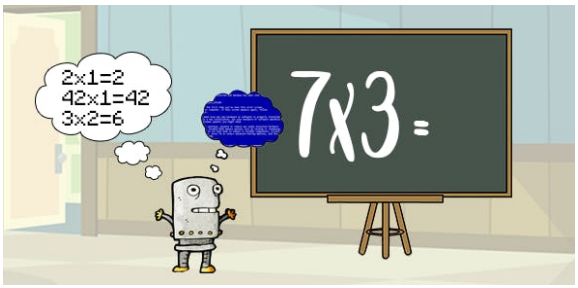
ES LA GENERALIZACIÓN LO QUE VALE

El objetivo fundamental del aprendizaje automático es generalizar más allá de los ejemplos del conjunto de entrenamiento.



Memorizar no es aprender

Hacerlo bien en el conjunto de entrenamiento es fácil (solo memoriza los ejemplos). El error más común entre los principiantes en aprendizaje automático es testear sobre los datos de entrenamiento y tener la ilusión de éxito.



Validación cruzada

En el caso de separar los datos, realizar una validación cruzada permite asegurar independencia de la partición.

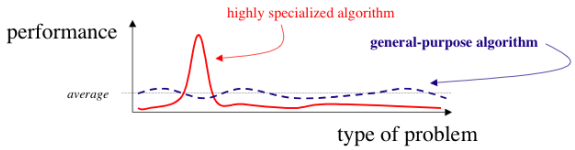


LOS DATOS POR SÍ SOLOS NO SON SUFICIENTES

El proceso de aprendizaje automático debe incorporar algún conocimiento o suposiciones más allá de los datos para poder generalizar.

No Free Lunch Theorem

Afirma que “dos algoritmos cualesquiera son equivalentes cuando su desempeño se promedia entre todos los problemas posibles”.



No existe la magia

Machine learning no es magia, no puede conseguir algo de la nada. Lo que hace es conseguir más por menos.



Hay que sembrar para cosechar

La programación es bastante trabajo, tenemos que diseñar y construir todo. En cambio, ML es más como la agricultura que permite a la naturaleza hacer la mayor parte del trabajo. Los agricultores combinan semillas con nutrientes para cultivar. Los expertos en aprendizaje automático combinan el conocimiento con los datos para hacer crecer los programas.



EL SOBREAJUSTE TIENE MUCHAS CARAS

Todo el mundo en el aprendizaje automático sabe sobre el sobreajuste, pero se presenta en muchas formas que no son inmediatamente obvias.

Falsa sensación de éxito

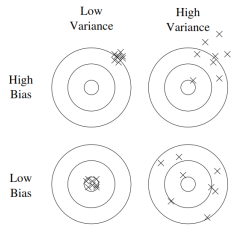
Si su modelo tiene una precisión del 100% sobre los datos de entrenamiento, pero solo un 50% sobre los datos de testing, cuando de hecho podría haber logrado un 75% de precisión en ambos datos, simplemente está codificando peculiaridades aleatorias en los datos y por lo tanto no está basado en la realidad. Este problema se denomina sobreajuste (*overfitting*) y es la pesadilla del aprendizaje automático.

	Low *Training* Error	High *Training* Error
Low *Testing* Error	The model is learning!	Probably some error in your code. Or you've created a *psychic* AI.
High *Testing* Error	OVERFITTING	The model is not learning.

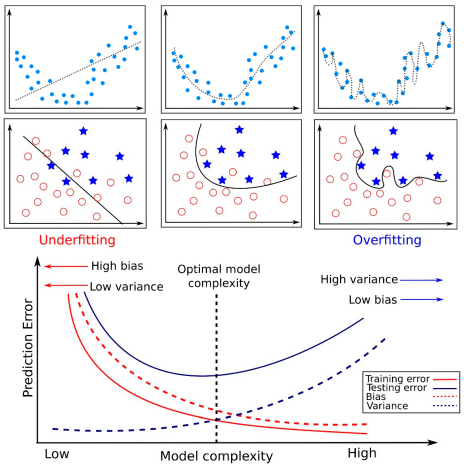
Sesgo y varianza

Una forma de entenderlo es descomponiendo el error en sesgo y varianza:

- Sesgo: Tendencia a aprender constantemente la misma cosa errónea.
- Varianza: Tendencia a aprender cosas aleatorias independientes del objetivo real.



Underfitting and Overfitting



Hay muchos métodos para combatir el sobreajuste

El más popular es la **regularización** que consiste en agregar un término de penalización a la función de pérdida.

Sin embargo, es fácil evitar el *overfitting* cayendo en el error opuesto conocido como *underfitting*.

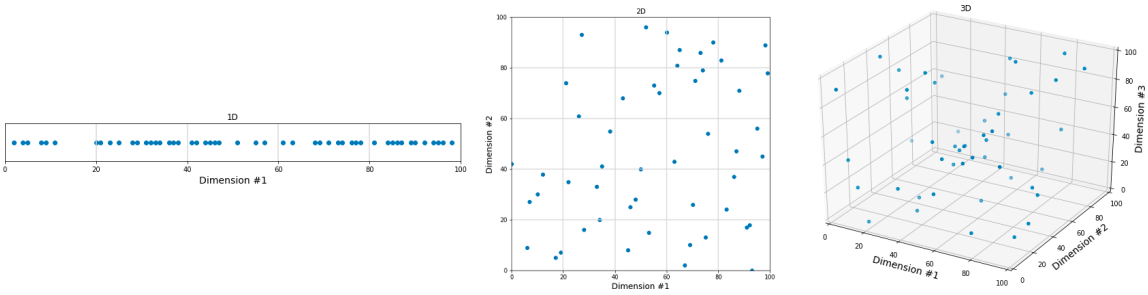
LA INTUICIÓN FALLA EN ALTAS DIMENSIONES

- Después del overfitting, el mayor problema en machine learning es la **maldición de la dimensionalidad**.

- Muchos algoritmos que funcionan bien en pocas dimensiones, se vuelven intratables cuando el input es de alta-dimensionalidad.

- Generalizar correctamente se vuelve exponencialmente más difícil cuando la dimensionalidad aumenta porque el conjunto de entrenamiento cubre cada vez menos el espacio de entrada.

Los datos se vuelven escasos y dispersos



Si tenemos 50 datos y dividimos el espacio en 5 partes, en 1D quedan 50/5 = 10 datos por parte, en 2D quedan 50/(5x5) = 2 datos por parte, y en 3D quedan 50/(5x5x5) = 0.4 datos por parte.

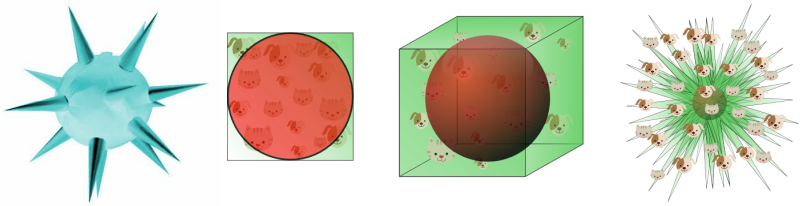
Nuestro mundo es en 3D

Incluso nuestras intuiciones, que provienen de un mundo tridimensional, no aplican en altas dimensiones. Por ejemplo:

- La mayor parte del volumen de una naranja de altas dimensiones está en la cáscara y no en la pulpa.



- La mayor parte del volumen de un cubo de alta dimensión se encuentra en sus esquinas.



La "Bendición de la no uniformidad"

- Afortunadamente, hay un efecto que contrarresta en parte esta maldición.
- Los datos no están distribuidos uniformemente por todo el espacio.
- Por lo tanto, podemos aplicar técnicas de reducción de la dimensionalidad.

LAS GARANTÍAS TEÓRICAS NO SON LO QUE PARECEN

Los papers de machine learning están llenos de garantías teóricas. El tipo más común es un límite en el número de ejemplos necesarios para asegurar una buena generalización o dados datos infinitos, se garantiza que el modelo encontrará la respuesta correcta.

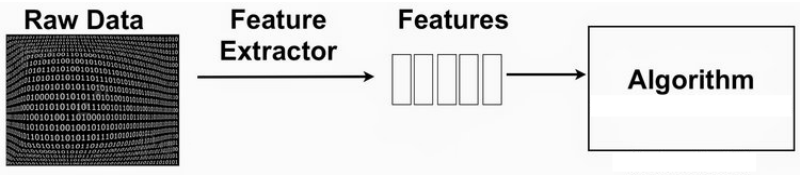
Cuidado con las garantías

Desafortunadamente, las garantías de este tipo deben tomarse con cautela.

- El rol de las garantías teóricas no es servir como criterio para tomar decisiones prácticas, sino como fuente de entendimiento para el diseño de algoritmos.
- Muy útiles por la estrecha relación entre la teoría y la práctica. Pero, el aprendizaje es un fenómeno complejo, y el hecho de que un modelo tenga una justificación teórica y funcione en la práctica no significa que lo primero sea la razón de lo segundo.

FEATURE ENGINEERING ES CLAVE

Un factor clave en el éxito o fracaso de una predicción son las *features* utilizadas.



Si se tienen muchas características independientes que se relacionan bien con la clase, el aprendizaje es sencillo.

Por otro lado, si la clase es una función muy compleja de las *features*, es posible que se no pueda aprender.

La clave del éxito

A menudo, los datos sin procesar no están en una forma que sea adecuada para el aprendizaje, pero se puede construir características a partir de ellos que lo sean. Por lo general, aquí es donde se concentra la mayor parte del esfuerzo en un proyecto de aprendizaje automático. A menudo es también una de las partes más interesantes, donde la intuición, la creatividad y la "magia negra" son tan importantes como la parte técnica.

Los novatos a menudo se sorprenden por el poco tiempo que se dedica en realidad al aprendizaje automático en un proyecto de aprendizaje automático. Pero tiene sentido si considera el tiempo que lleva recopilar datos, integrarlos, limpiarlos y preprocesarlos, y cuánto ensayo y error puede implicar el diseño de características.

Es un proceso iterativo

Además, el aprendizaje automático no es un proceso lineal, sino un proceso iterativo que consiste en ejecutar el modelo, analizar los resultados, modificar los datos, ajustar el modelo, y repetir esto muchas veces hasta lograr el éxito.

El aprendizaje suele ser la parte más rápida de esto y la ingeniería de características la más difícil porque es específica del dominio, mientras que los modelos pueden ser en gran medida de propósito general. Sin embargo, no existe una frontera clara entre los dos.

MÁS DATOS PUEDEN VENCER A LA INTELIGENCIA

Suponiendo que se tiene el mejor conjunto de features posible, pero no se logra la precisión necesaria. ¿Qué hacer?

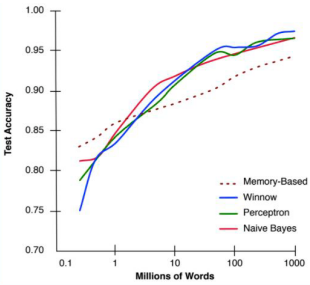
Hay dos alternativas posibles:

- Diseñar un mejor algoritmo de aprendizaje.
- Reunir más datos.

Los investigadores de aprendizaje automático se preocupan principalmente por lo primero, pero pragmáticamente, el camino más rápido hacia el éxito suele ser obtener más datos.

Regla no escrita

Un algoritmo débil con muchos datos supera a uno más complejo con pocos datos (después de todo, el aprendizaje automático se trata de dejar que los datos hagan el trabajo pesado).



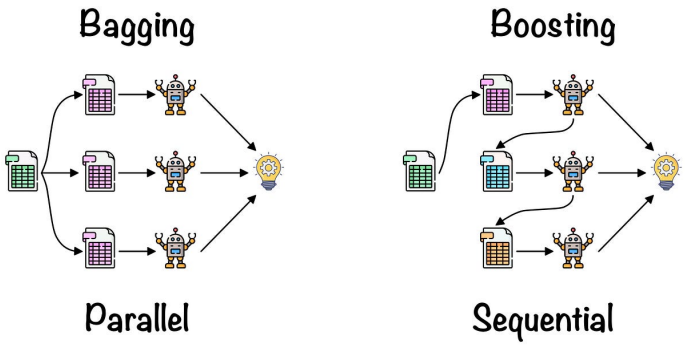
“It's not who has the best algorithms that wins. It's who has the most data.” (Banko and Brill, 2001)

APRENDE MUCHOS MODELOS, NO SOLO UNO

En los comienzos de machine learning, se comparaban entre distintos algoritmos de aprendizaje y se elegía el mejor para cada aplicación. Sin embargo, los resultados demostraban que el mejor variaba con la aplicación.

Ensamblados

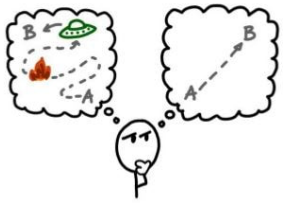
Si en lugar de seleccionar el mejor se combinan (*ensembles*), se obtienen mejores resultados.



SIMPLICIDAD NO IMPLICA PRECISIÓN

Principio "La navaja de Occam"

“En igualdad de condiciones, la explicación más sencilla suele ser la correcta, no deben multiplicarse las entidades sin necesidad”



La simplicidad por ser simple

- En machine learning esto se puede entender así: "Entre dos modelos con el mismo error en training, el más simple tendrá el menor error en testing."

- Sin embargo, se pueden encontrar muchos ejemplos que afirman lo contrario.

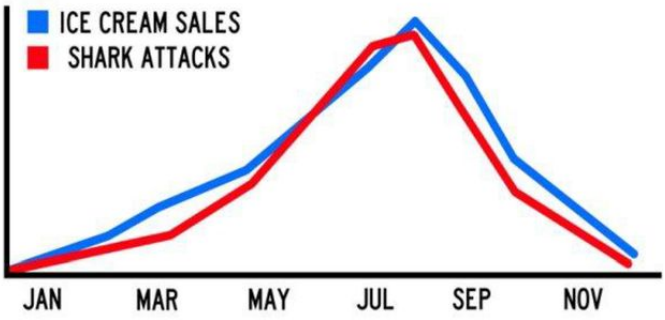
La conclusión sobre este principio es que una hipótesis simple es preferible porque la simplicidad es una virtud en sí misma, pero no implica un aumento en la precisión.

REPRESENTABLE NO IMPLICA APRENDIBLE

Sólo porque una función pueda ser representada no significa que pueda ser aprendida.

La pregunta clave no es ¿Puede representarse? es **¿Puede aprenderse?**

CORRELACIÓN NO IMPLICA CAUSALIDAD



¿Causalidad o casualidad?

Algunos investigadores creen que la causalidad es sólo una conveniente ficción, incluso en las leyes de la física.

De todos modos, la correlación permite conocer la conexión entre variables y podemos usarla como guía para un mayor entendimiento del fenómeno y una mayor investigación.

Conclusión

Como en cualquier otra disciplina, para tener éxito en machine learning se requiere experiencia y sabiduría que se consigue con el tiempo, aunque a veces puede ser díficil de obtener.