IPD440 - APRENDIZAJE DE MAQUINAS

Clase 21: World Models

Prof. Nicolás Torres
nicolas.torresr@usm.cl
Ingeniería Civil Telemática
Departamento de Electrónica
Universidad Técnica Federico Santa María

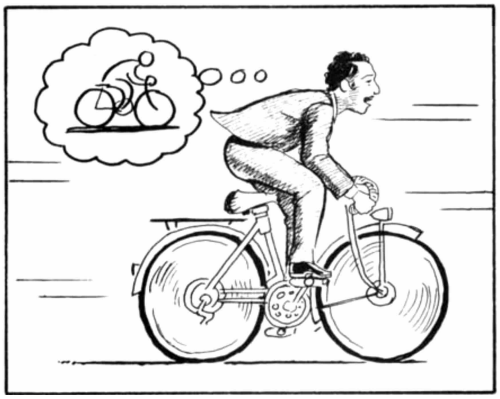
Introduction

> "The image of the world around us, which we carry in our head, is just a model. Nobody in his head imagines all the world, government or country. He has only selected concepts, and relationships between them, and uses those to represent the real system." — Jay Wright Forrester



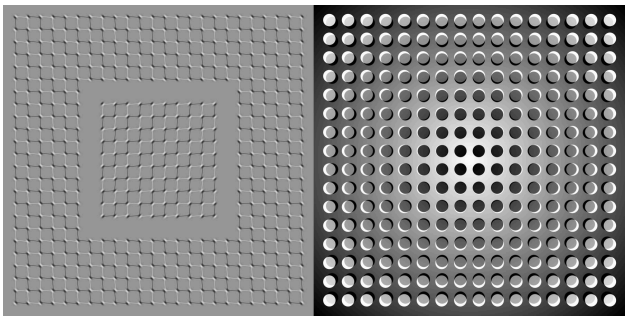
Introduction

Los seres humanos desarrollamos un modelo mental del mundo basado en lo que podemos percibir con nuestros sentidos limitados. Las decisiones y acciones que tomamos se basan en este modelo interno.



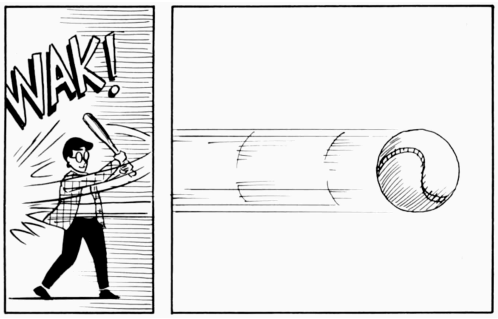
Introduction

Para manejar la enorme cantidad de información que fluye a través de nuestra vida diaria, nuestro cerebro aprende una representación abstracta de los aspectos espaciales y temporales de esta información. Somos capaces de observar una escena y recordar una descripción abstracta de la misma. La evidencia también sugiere que lo que percibimos en un momento dado está regido por la predicción del futuro que hace nuestro cerebro en función de nuestro modelo interno.



Introduction

Por ejemplo, un bateador de béisbol tiene milisegundos para decidir cómo debe batear, un tiempo menor que el que tardan las señales visuales de nuestros ojos en llegar a nuestro cerebro. La razón por la que podemos batear una bola rápida a 160 km/h se debe a nuestra capacidad de predecir instintivamente cuándo y dónde irá la pelota. Los profesionales pueden actuar rápidamente según sus predicciones del futuro sin necesidad de desarrollar conscientemente posibles escenarios futuros para elaborar un plan.



Can agents learn inside of their own dreams?

En marzo de 2018, David Ha y Jürgen Schmidhuber publicaron su artículo “World Models”. El artículo mostraba cómo es posible entrenar un modelo que puede aprender a realizar una tarea particular mediante la experimentación dentro de su propio entorno de sueño generado, en lugar de dentro del entorno real.



Model-free vs Model-based

Los enfoques de RL *Model-free*, que aprenden a predecir acciones exitosas mediante ensayo y error, han permitido que los agentes jueguen juegos de Atari y que derroten a campeones mundiales en Starcraft II, pero requieren grandes cantidades de interacción con el entorno, lo que limita su utilidad para escenarios del mundo real.

Por el contrario, los enfoques de RL *Model-based* aprenden un modelo simplificado del entorno. Este modelo del mundo posibilita al agente predecir los resultados de posibles secuencias de acciones, lo que le permite jugar con escenarios hipotéticos para tomar decisiones informadas en nuevas situaciones, reduciendo así el ensayo y error necesario para alcanzar los objetivos.

SketchRNN

SketchRNN es un modelo generativo basado en redes neuronales recurrentes (RNNs) diseñado para crear y completar dibujos de líneas simples, como bocetos de figuras o formas.

https://magenta.tensorflow.org/assets/sketch_rnn_demo/index.html

Utiliza una variación de una red seq-to-seq que aprende a representar dibujos como secuencias de acciones de dibujo (por ejemplo, moverse, levantar el lápiz, trazar una línea), y permite generar o predecir dibujos basándose en ejemplos de datos de entrenamiento.

Dreamer

Dreamer es un modelo de Google DeepMind, y al igual que en World Models utiliza:

- **Un modelo latente:** Dreamer crea un espacio latente que codifica las dinámicas del entorno, lo que permite predicciones precisas de las consecuencias de acciones futuras.
- **Simulación interna:** Los "episodios imaginados" o simulaciones internas le permiten al agente anticipar resultados antes de actuar en el entorno real.
- **Planificación en el espacio latente:** Ambos modelos aprovechan las predicciones en el espacio latente para optimizar la política del agente, lo que ahorra recursos y mejora la

eficiencia.

How Does Dreamer Work?



Los tres procesos del agente: El modelo del mundo se aprende a partir de la experiencia pasada. A partir de las predicciones de este modelo, el agente aprende una red de valores para predecir recompensas futuras y una red de actores para seleccionar acciones. La red de actores se utiliza para interactuar con el entorno.

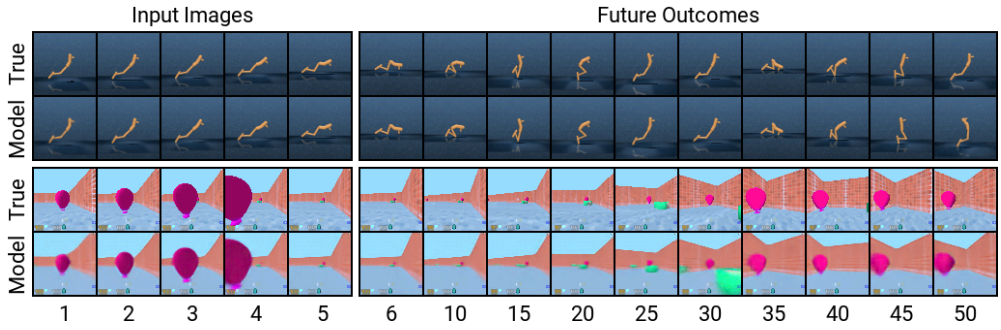
Learning the World Model



Dreamer aprende un modelo del mundo a partir de su experiencia. Utilizando imágenes pasadas ($o_1 - o_3$) y acciones ($a_1 - a_2$), calcula una secuencia de estados compactos del modelo (círculos verdes) a partir de los cuales reconstruye las imágenes ($\hat{o}_1 - \hat{o}_3$) y predice las recompensas ($\hat{r}_1 - \hat{r}_3$).

Learning the World Model

La predicción anticipada mediante estados de modelos compactos permite realizar predicciones a largo plazo en entornos complejos. Aquí se muestran dos secuencias que el agente no ha encontrado antes. Dadas cinco imágenes de entrada, el modelo las reconstruye y predice las imágenes futuras hasta el paso de tiempo 50.



Performance on Control Tasks

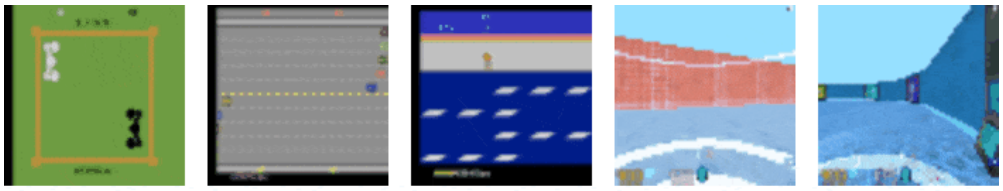
Dreamer aprende a resolver 20 desafiantes tareas de control continuo con entradas de imágenes, 5 de las cuales se muestran aquí. Las visualizaciones muestran las mismas imágenes de 64x64 que el agente recibe del entorno.



Sparse Cartpole | Acrobot Swingup | Hopper Hop | Walker Run | Quadruped Run

Performance on Control Tasks

Dreamer aprende comportamientos exitosos en los juegos de Atari y en los niveles de DeepMind Lab, que presentan acciones discretas y escenas visualmente más diversas, incluidos entornos 3D con múltiples objetos.



Boxing | Freeway | Frostbite | Collect Objects | Watermaze